

**OMIS-Statistiques**  
**Feuille de travaux dirigés numéro 1**  
**Régression linéaire**

**Exercice 1**

La méthode Ridge consiste à chercher  $\hat{\beta}$  qui minimise la fonction

$$\beta \mapsto \|Y - X\beta\|^2 + \lambda\|\beta\|^2.$$

Ce minimiseur est appelé l'estimateur Ridge.

1. Soit  $A$  une matrice carrée. Montrer que pour  $\lambda > 0$  suffisamment petit,  $\lambda Id + A$  est inversible.
2. Calculer l'estimateur Ridge  $\hat{\beta}$ .
3. Quelle est sa limite lorsque  $\lambda \rightarrow \infty$  ?  
On suppose que  $X$  est de plein rang.
4. Quelle est la limite de  $\hat{\beta}$  lorsque  $\lambda \rightarrow 0$  ?
5. Que vaut  $\hat{\beta}$  lorsque les colonnes de  $X$  sont orthonormales ?
6. Calculer le biais et la variance de cette estimateur.

**Exercice 2**

On examine l'évolution d'une variable  $Y$  en fonction de deux variables  $X_1$  et  $X_2$ . On dispose de  $n$  observations de ces variables. On note  $X = (\mathbf{1}, X_1, X_2)$  où  $\mathbf{1}$  est le vecteur constant.

1. Nous obtenons le résultat suivant :

$$X^T X = \begin{pmatrix} 30 & 0 & 0 \\ ? & 10 & 7 \\ ? & ? & 15 \end{pmatrix}$$

- a) Donner les valeurs manquantes.
  - b) Que vaut  $n$  ?
  - c) Calculer le coefficient de corrélation empirique entre  $X_1$  et  $X_2$ .
2. La régression linéaire de  $Y$  sur  $X$  donne

$$Y = -2\mathbf{1} + X_1 + 2X_2 + \hat{\varepsilon}, \text{ avec } \text{RSS} = \|\hat{\varepsilon}\|^2 = 12.$$

- a) Déterminer la moyenne arithmétique  $\bar{Y}$ .
- b) Calculer la somme des carrés expliquée (ESS), la somme des carrés totale (TSS) et le coefficient de corrélation  $R^2$ .

**Exercice 3**

Soit  $Y = X\beta + \varepsilon$  un modèle de régression linéaire pour la concentration en ozone ( $Y$ ) en fonction de la température  $X_1$ , du vent  $X_2$  et de la nébulosité  $X_3$ . On veut tester la pertinence de l'influence du vent sur la concentration en ozone. Les données permettent d'obtenir

$$\begin{aligned} \hat{\sigma}^2 &= 9, \\ \hat{Y} &= (4, 4, 5, 3.2, 3.4, 7.3), \\ \hat{Y}^* &= (3, 3.2, 5, 3, 3.7, 7). \end{aligned}$$

Peut-on rejeter l'impertinence du vent ?

#### Exercice 4

Nous considérons le modèle de régression linéaire

$$Y = X\beta + \varepsilon,$$

où  $Y \in \mathbb{R}^n$ ,  $X$  est une matrice de taille  $n \times p$  composée de  $p$  vecteurs orthogonaux,  $\beta \in \mathbb{R}^p$  et  $\varepsilon \in \mathbb{R}^n$ . Considérons  $U$  la matrice des  $q$  premières colonnes de  $X$  et  $V$  la matrice des  $p - q$  dernières colonnes de  $X$ . On obtient par les MCO les estimations suivantes :

$$\begin{aligned}\hat{Y}_X &= \hat{\beta}_1^X X_1 + \dots + \hat{\beta}_p^X X_p \\ \hat{Y}_U &= \hat{\beta}_1^U X_1 + \dots + \hat{\beta}_q^U X_q \\ \hat{Y}_V &= \hat{\beta}_{q+1}^V X_{q+1} + \dots + \hat{\beta}_p^V X_p\end{aligned}$$

On note  $\text{ESS}(A)$  la norme au carré de la projection de  $Y$  sur  $\text{Im}(A)$ .

1. Montrer que  $\text{ESS}(X) = \text{ESS}(U) + \text{ESS}(V)$ .
2. Pour une variable  $X_i$ , montrer que l'estimation de  $\beta_i$  est identique quel que soit le modèle utilisé.

#### Exercice 5

Soit un modèle de régression  $Y = X\beta + \varepsilon$ . La dernière colonne (la  $p^{\text{eme}}$ ) de  $X$  est le vecteur  $\mathbf{1}$ .

1. Soient les variables  $\{X_j\}_{j=1,\dots,p}$  et  $Y$  et celles centrées notées  $\{X'_j\}_{j=1,\dots,p}$  et  $Y'$ . Montrer que la dernière colonne de  $X'$  regroupant les variables  $\{X'_p\}$  vaut 0.
2. On note maintenant  $X'$  la matrice  $X$  centrée et privée de sa dernière colonne de 0 (elle est donc de dimension  $n \times p - 1$ ).

Soit le modèle suivant :  $Y' = X'\beta' + \varepsilon$ . En identifiant ce modèle avec le modèle de régression  $Y = X\beta + \varepsilon$ , trouver la valeur de  $\beta_p$  en fonction de  $\beta'_1, \dots, \beta'_{p-1}$  et des moyennes empiriques de  $Y$  et de  $X$ . Ce coefficient est appelé coefficient constant (ou *intercept* en anglais).